

INFORME PROYECTO NLP PARA PROMPT INJECTION

Por Rocío Arias

Mentor: Yunier Córdova

07 / Mayo / 2026

- **Abstract e Introducción**

El estudio aborda el *Prompt Injection* como vulnerabilidad crítica en LLMs. El objetivo es implementar un clasificador defensivo que categorice mensajes en tres niveles (*benign*, *suspicious*, *prompt_injection*), analizando patrones lingüísticos y estructurales para proteger entornos corporativos.

- **Metodología**

Sobre un corpus de 38,729 registros, se ejecutó un pipeline de cinco fases:

1. **Datos:** Auditoría de integridad y mapeo de etiquetas por severidad.
2. **Procesamiento:** Limpieza selectiva (preservando símbolos estructurales) y vectorización TF-IDF con Bigramas.
3. **Ingeniería de Características:** Extracción de ratios de mayúsculas y densidad de caracteres especiales.
4. **Visualización:** Uso de t-SNE 3D para validar la separabilidad de clases.
5. **Modelado:** Regresión Logística con pesos balanceados para compensar la baja frecuencia de ataques.

- **Resultados, Discusión y Conclusión**

El modelo logró un **Recall específico superior al 90%** en inyecciones, priorizando la detección de falsos negativos. Se concluye que esta arquitectura es una capa de seguridad proactiva, robusta e interpretable,

Bibliografía (Formato APA)

- American Psychological Association. (2020). *Publication manual* (7th ed.).
- Pedregosa, F., et al. (2011). Scikit-learn. *JMLR*.
- Salton, G., & Buckley, C. (1988). Term-weighting approaches. *IP&M*.
- Van der Maaten, L., & Hinton, G. (2008). Visualizing Data using t-SNE. *JMLR*.
- Barcelona Activa. (2024). *Ciberseguridad en la industria 4.0*.
- Passionfruit Pulse. (2025). *AI prompt engineering for accurate citations*.